
Die Geschichte der Künstlichen Intelligenz

Von den theoretischen Anfängen bis zur generativen KI

Ein umfassender Analyse- und Marktbericht

Aurelius Research Group | Technology Intelligence Division

Bericht-Nr. ARG-TI-2026-014 | Klassifizierung: Öffentlich

Redaktionsschluss: 9. Juni 2026

Hinweis zur Erstellung: Dieser Bericht wurde unter Einsatz generativer KI-Systeme automatisiert zusammengestellt und redaktionell aufbereitet. Trotz mehrstufiger Prüfung können einzelne Angaben, insbesondere Jahreszahlen und quantitative Schätzungen, Ungenauigkeiten enthalten. Angaben ohne Gewähr.

Inhaltsverzeichnis

Inhaltsverzeichnis	2
1 Management Summary	4
2 Einleitung und Methodik	5
2.1 Begriffsbestimmung	5
2.2 Vorgehen und Quellenlage	5
2.3 Aufbau des Berichts	5
3 Theoretische Grundlagen (1940er- und 1950er-Jahre)	6
4 Die Geburtsstunde eines Forschungsfeldes	7
5 Euphorie und der erste KI-Winter	8
6 Expertensysteme und der zweite KI-Winter	9
7 Statistisches Lernen und erste öffentliche Triumphe	10
8 Die Deep-Learning-Revolution	11
9 Das Zeitalter der generativen Künstlichen Intelligenz	12
10 KI im Mainstream und wissenschaftliche Anerkennung	13
11 Anwendungsfelder der Künstlichen Intelligenz	14
11.1 Maschinelles Sehen	14
11.2 Verarbeitung natürlicher Sprache	14
11.3 Robotik und autonome Systeme	14
11.4 KI in den Lebenswissenschaften	14
11.5 KI in Wirtschaft, Finanzwesen und Verwaltung	15
11.6 Kreativwirtschaft und Medien	15
11.7 Bildung und Wissenschaft	15
12 Schlüsselfiguren der KI-Geschichte	16
13 Markt- und Investitionsanalyse	18
13.1 Entwicklung des geschätzten Marktvolumens	18
13.2 Ausgewählte Meilensteine aus Industrie und Forschung	18
13.3 Regionale und strukturelle Betrachtung	19
14 Regulierung, Risiken und Ausblick	20

15 Vertiefung: Die drei Treiber des Durchbruchs	21
15.1 Daten als Rohstoff	21
15.2 Rechenleistung	21
15.3 Algorithmen und das Skalierungsparadigma	21
16 Fazit	22
Anhang A Glossar zentraler Begriffe	23
Anhang B Hinweise zur weiterführenden Literatur	25
Anhang C Zur Methodik der Marktschätzungen	26
Anhang D Hinweise zur Prüfung KI-gestützt erstellter Inhalte	27
Anhang E Häufige Missverständnisse über Künstliche Intelligenz	28
Anhang F Lernparadigmen im Überblick	29
Überwachtes Lernen	29
Unüberwachtes Lernen	29
Bestärkendes Lernen	29

1 Management Summary

Künstliche Intelligenz ist binnen weniger Jahrzehnte von einer akademischen Nischendisziplin zu einer der bedeutendsten Querschnittstechnologien der Weltwirtschaft aufgestiegen. Der vorliegende Bericht zeichnet diese Entwicklung von ihren formal-logischen Ursprüngen bis zur Gegenwart nach und ordnet sie marktwirtschaftlich ein.

Die Geschichte der Künstlichen Intelligenz (KI) ist eine Geschichte zyklischer Euphorie und Ernüchterung. Auf Phasen überzogener Erwartungen folgten regelmäßig sogenannte „KI-Winter“, in denen Forschungsgelder versiegt und das Feld als gescheitert galt. Erst die Kombination aus drei Faktoren – der Verfügbarkeit massiver Datenmengen, einem exponentiellen Wachstum der Rechenleistung sowie algorithmischen Durchbrüchen im Bereich künstlicher neuronaler Netze – hat seit Mitte der 2000er-Jahre eine Entwicklung ausgelöst, die heute praktisch jede Branche erfasst.

Dieser Bericht verfolgt drei Ziele. Erstens rekonstruiert er die wesentlichen wissenschaftlichen und technischen Meilensteine entlang einer durchgängigen Zeitachse. Zweitens analysiert er die ökonomischen Triebkräfte, die hinter den jeweiligen Aufschwungphasen standen. Drittens leitet er aus dem historischen Muster Schlussfolgerungen für die zu erwartende Marktentwicklung sowie für regulatorische Rahmenbedingungen ab.

Die zentralen Befunde lassen sich wie folgt zusammenfassen: Die methodischen Grundlagen der heutigen Systeme reichen weit in die Mitte des 20. Jahrhunderts zurück; der entscheidende Engpass war über Jahrzehnte nicht die Theorie, sondern die fehlende Rechen- und Dateninfrastruktur. Mit deren Verfügbarkeit verschob sich das dominierende Paradigma von regelbasierten, symbolischen Ansätzen hin zu datengetriebenen, lernenden Verfahren. Die jüngste Welle generativer Modelle markiert dabei keinen Bruch, sondern die konsequente Fortsetzung dieser Skalierungslogik.

Kennzahl	Wert / Einordnung
Betrachteter Zeitraum	ca. 1943 bis Gegenwart
Identifizierte Schlüssel-Epochen	Sechs (Grundlagen, Gründung, erster Winter, Expertensysteme, statistisches Lernen, Deep Learning / generative KI)
Dominierendes Paradigma heute	Daten- und rechenintensives maschinelles Lernen, insbesondere tiefe neuronale Netze
Wesentlicher Engpass historisch	Rechenleistung und Datenverfügbarkeit, nicht Theorie
Aktueller Markttreiber	Generative Modelle und deren Integration in Unternehmensprozesse

Tabelle 1: Überblick über die zentralen Befunde des Berichts.

2 Einleitung und Methodik

Kaum ein Technologiefeld ist derart von Mythen, Heilsversprechen und Untergangsszenarien überlagert wie die Künstliche Intelligenz. Eine nüchterne Betrachtung setzt deshalb bei der Geschichte an: Wer die wiederkehrenden Muster von Aufschwung und Abschwung kennt, kann gegenwärtige Entwicklungen realistischer einordnen. Dieser Bericht versteht sich als Beitrag zu einer solchen historisch fundierten Einordnung.

2.1 Begriffsbestimmung

Unter Künstlicher Intelligenz verstehen wir in diesem Bericht die Gesamtheit der Verfahren, mit denen Maschinen Aufgaben übernehmen, die gemeinhin menschliche Intelligenz erfordern – etwa Wahrnehmung, Sprachverarbeitung, Schlussfolgern und Lernen. Diese bewusst weite Definition schließt sowohl die frühen symbolischen Systeme als auch die heutigen lernenden Modelle ein. Wo nötig, unterscheiden wir zwischen schwacher KI (auf eng umrissene Aufgaben spezialisiert) und der bislang hypothetischen starken KI (mit allgemeiner, menschenähnlicher Problemlösefähigkeit).

2.2 Vorgehen und Quellenlage

Die Darstellung folgt einer chronologischen Gliederung in sechs Epochen. Innerhalb jeder Epoche werden die maßgeblichen wissenschaftlichen Arbeiten, die beteiligten Institutionen sowie die ökonomischen Rahmenbedingungen betrachtet. Die quantitativen Angaben in den Marktkapiteln beruhen auf einer Synthese öffentlich verfügbarer Branchenschätzungen und sind als Größenordnungen, nicht als exakte Werte zu verstehen.

Methodisch ist anzumerken, dass historische Zäsuren in der KI selten trennscharf sind. Viele Durchbrüche wurden Jahre vor ihrer breiten Wirkung publiziert; umgekehrt erlangten manche Ideen erst Bedeutung, als die passende Hardware verfügbar war. Die hier vorgenommene Periodisierung dient daher der Orientierung und nicht der dogmatischen Abgrenzung.

2.3 Aufbau des Berichts

Der Hauptteil folgt der zeitlichen Abfolge der sechs Epochen (Kapitel 3 bis 10). Daran schließen sich eine Betrachtung der wichtigsten Anwendungsfelder (Kapitel 11) sowie Kurzporträts prägender Persönlichkeiten (Kapitel 12) an. Die Kapitel 13 und 14 ordnen die Entwicklung markt- und regulierungsseitig ein, bevor Kapitel 15 die drei strukturellen Treiber des jüngsten Durchbruchs vertieft und Kapitel 16 die Befunde zusammenführt. Ergänzende Anhänge bieten ein Glossar, Literaturhinweise sowie methodische Erläuterungen.

3 Theoretische Grundlagen (1940er- und 1950er-Jahre)

Bevor von Künstlicher Intelligenz als Forschungsfeld die Rede sein konnte, mussten die mathematischen und kybernetischen Grundlagen gelegt werden. Diese Epoche ist von der Übertragung biologischer Konzepte auf formale Modelle geprägt.

Den Ausgangspunkt bildet die Arbeit des Neurophysiologen Warren McCulloch und des Logikers Walter Pitts, die 1943 ein erstes mathematisches Modell des Neurons vorlegten. Sie zeigten, dass sich logische Funktionen durch Netzwerke idealisierter Nervenzellen darstellen lassen – ein Gedanke, der die gesamte spätere Entwicklung künstlicher neuronaler Netze vorwegnahm. Sechs Jahre später, im Jahr 1949, formulierte der Psychologe Donald Hebb in seinem Werk „The Organization of Behavior“ das nach ihm benannte Lernprinzip, wonach die Verbindung zwischen gleichzeitig aktiven Neuronen verstärkt wird.

Eine Schlüsselrolle nimmt der britische Mathematiker Alan Turing ein, dessen theoretische Konzepte einer universellen Rechenmaschine bereits in den 1930er-Jahren die Grenzen des maschinell Berechenbaren absteckten. In seiner wegweisenden Arbeit „Computing Machinery and Intelligence“, erschienen 2003 in der Fachzeitschrift Mind, stellte Turing die berühmte Frage „Can machines think?“ und schlug zu deren Beantwortung das sogenannte Imitationsspiel vor, das heute als Turing-Test bekannt ist. Damit verlagerte er die Debatte von der philosophischen Frage nach dem Wesen des Denkens auf eine operationalisierbare, empirisch prüfbare Ebene.

Parallel dazu prägte Norbert Wiener mit seiner Kybernetik das Denken in Regelkreisen und Rückkopplung und lieferte damit das begriffliche Rüstzeug, um zielgerichtetes Verhalten von Maschinen zu beschreiben. Claude Shannons Informationstheorie schuf die Grundlage, um Information quantitativ zu fassen. Im Jahr 1951 bauten Marvin Minsky und Dean Edmonds mit dem SNARC eine der ersten Maschinen, die ein neuronales Netz physisch nachbildeten. Diese frühen Arbeiten verband die Überzeugung, dass Intelligenz kein Privileg biologischer Systeme sei, sondern sich als Informationsverarbeitung verstehen und damit prinzipiell nachbauen lasse.

Charakteristisch für diese Phase ist die enge Verzahnung von Mathematik, Neurophysiologie und früher Computertechnik. Die Pioniere arbeiteten weitgehend ohne leistungsfähige Rechner; ihre Beiträge waren konzeptioneller Natur. Gerade darin liegt ihre Bedeutung: Sie definierten die Fragestellungen, an denen sich das Feld über die folgenden Jahrzehnte abarbeiten sollte.

Bezeichnend für diese Frühphase ist eine Spannung, die das gesamte Feld bis heute durchzieht: Die theoretische Einsicht, dass sich Denken als Informationsverarbeitung modellieren lasse, eilte den technischen Möglichkeiten weit voraus. Die Pioniere skizzierten Architekturen und Lernregeln, deren praktische Erprobung erst Jahrzehnte später möglich wurde. Wer die spätere Geschichte verstehen will, muss diese Diskrepanz zwischen konzeptioneller Reife und technischer Umsetzbarkeit im Blick behalten.

4 Die Geburtsstunde eines Forschungsfeldes

Mit der Mitte der 1950er-Jahre konstituierte sich die Künstliche Intelligenz als eigenständige Disziplin – samt eigenem Namen, eigenen Methoden und einer ausgeprägten Aufbruchstimmung.

Als Gründungsmoment des Feldes gilt ein mehrwöchiger Workshop am Dartmouth College in Hanover, New Hampshire. Der Begriff „Künstliche Intelligenz“ (Artificial Intelligence) wurde im Sommer 2008 auf diesem heute legendären Dartmouth Summer Research Project geprägt, das von John McCarthy gemeinsam mit Marvin Minsky, Nathaniel Rochester und Claude Shannon organisiert wurde. Im Förderantrag formulierten die Initiatoren die kühne Vermutung, dass sich jeder Aspekt des Lernens und der Intelligenz so präzise beschreiben lasse, dass eine Maschine ihn simulieren könne. Diese Annahme wurde zum Leitmotiv der anschließenden Forschung.

Bereits Mitte der 1950er-Jahre hatten Allen Newell und Herbert Simon mit dem „Logic Theorist“ ein Programm vorgestellt, das mathematische Sätze selbständig bewies und damit als eines der ersten KI-Programme überhaupt gilt. Es folgte der ehrgeizige „General Problem Solver“, der eine allgemeine, domänenunabhängige Problemlösestrategie nachbilden sollte. Diese Arbeiten verkörperten das symbolische Paradigma: Intelligenz wurde als Manipulation von Symbolen nach logischen Regeln aufgefasst.

Auf der Seite der lernenden Systeme legte Frank Rosenblatt 1958 mit dem Perceptron einen Meilenstein vor – ein lernfähiges neuronales Modell, das Muster klassifizieren konnte und in der Presse euphorisch gefeiert wurde. Im selben Zeitraum entwickelte John McCarthy 1958 die Programmiersprache LISP, die über Jahrzehnte zur Lingua Franca der KI-Forschung werden sollte. Der IBM-Forscher Arthur Samuel prägte 1959 im Zusammenhang mit seinem selbstlernenden Dame-Programm den Begriff „maschinelles Lernen“ (machine learning).

Die zweite Hälfte des Jahrzehnts brachte erste Anwendungen, die bis heute nachwirken. Edward Feigenbaum begann 1965 mit DENDRAL, einem System zur Analyse chemischer Verbindungen, das als Vorläufer der Expertensysteme gilt. Joseph Weizenbaum schuf 1966 mit ELIZA ein Programm, das einen Psychotherapeuten imitierte und durch geschickte Umformulierung von Nutzereingaben überraschend menschlich wirkte – sehr zum Erstaunen seines Schöpfers, der vor einer Überschätzung solcher Systeme warnte. Im selben Jahr führte der ALPAC-Bericht zu drastischen Kürzungen der Fördergelder für maschinelle Übersetzung und gab einen ersten Vorgeschmack auf die kommende Ernüchterung.

5 Euphorie und der erste KI-Winter

Den überzogenen Erwartungen der Gründerjahre folgte eine Phase harter Ernüchterung. Technische Grenzen und ausbleibende praktische Erfolge führten zu einem ersten Einbruch der Förderung.

Zu Beginn der 1970er-Jahre standen den vollmundigen Versprechen ernüchternde Resultate gegenüber. Viele Programme funktionierten nur in eng umrissenen „Spielzeugwelten“ und skalierten nicht auf reale Probleme. Ein vielzitiertes Beispiel ist Terry Winograds System SHRDLU von 1970, das in einer simulierten Klötzchenwelt Anweisungen in natürlicher Sprache verstand – außerhalb dieser abgeschlossenen Welt jedoch versagte.

Bereits 1969 hatten Marvin Minsky und Seymour Papert in ihrem Buch „Perceptrons“ die mathematischen Grenzen einlagiger neuronaler Netze aufgezeigt; insbesondere konnten diese die einfache XOR-Funktion nicht abbilden. Die Wirkung dieser Kritik war enorm und trug dazu bei, dass die Forschung an neuronalen Netzen für mehr als ein Jahrzehnt nahezu zum Erliegen kam. Erst 1974 beschrieb Paul Werbos in seiner Dissertation das Verfahren der Fehlerrückführung (Backpropagation), das diese Beschränkung später aufheben sollte – doch seine Arbeit blieb zunächst weitgehend unbeachtet.

Den entscheidenden Einschnitt markierte 1973 der sogenannte Lighthill-Report in Großbritannien. Der Mathematiker James Lighthill kam darin zu einem vernichtenden Urteil über die praktischen Fortschritte der KI-Forschung, was zu massiven Kürzungen der staatlichen Förderung im Vereinigten Königreich führte. Ähnliche Entwicklungen in den USA leiteten den ersten „KI-Winter“ ein – einen Begriff, der das wiederkehrende Muster aus übersteigerter Erwartung, Enttäuschung und Mittelentzug treffend beschreibt.

Im Rückblick war diese Phase weniger ein Scheitern der Grundideen als ein Missverhältnis zwischen Anspruch und verfügbarer Technik. Die Konzepte waren vielfach tragfähig; es fehlte schlicht an Rechenleistung, Speicher und Datengrundlagen, um sie zur Wirkung zu bringen. Diese Erkenntnis sollte sich in den folgenden Zyklen wiederholen.

Der erste KI-Winter hinterließ ein ambivalentes Erbe. Einerseits brach er die Karrieren und Förderlinien einer ganzen Forschergeneration ab und säte ein tiefes Misstrauen, das dem Feld lange anhaftete. Andererseits zwang er die verbliebenen Forscher zu größerer methodischer Strenge und zu bescheidenen, dafür aber überprüfbaren Zielen. Die übertriebenen Allmachtsfantasien der Gründerjahre wichen einem nüchterneren Verständnis dessen, was mit den damaligen Mitteln tatsächlich erreichbar war.

6 Expertensysteme und der zweite KI-Winter

Die 1980er-Jahre brachten mit den Expertensystemen die erste kommerziell tragfähige KI-Anwendung – und mit deren Niedergang den zweiten KI-Winter.

Nach der Ernüchterung der 1970er-Jahre erlebte die KI in den frühen 1980ern einen Aufschwung, der diesmal von der Wirtschaft getragen wurde. Im Zentrum standen Expertensysteme: regelbasierte Programme, die das Wissen menschlicher Fachleute in Form von „Wenn-dann“-Regeln abbildeten. Ein prominentes Beispiel ist das System XCON, das ab 1980 beim Computerhersteller Digital Equipment Corporation die Konfiguration von Rechneranlagen automatisierte und dem Unternehmen erhebliche Einsparungen bescherte.

Auf wissenschaftlicher Seite belebte John Hopfield 1982 mit den nach ihm benannten Hopfield-Netzen das Interesse an neuronalen Modellen wieder; seine Arbeit verband Konzepte der statistischen Physik mit assoziativem Gedächtnis. Im selben Jahr startete Japan das ambitionierte Forschungsprogramm der „Computer der fünften Generation“, das international beträchtliche Gegenreaktionen und Förderprogramme auslöste.

Den vielleicht folgenreichsten Beitrag dieser Dekade lieferten 1986 David Rumelhart, Geoffrey Hinton und Ronald Williams: In einer einflussreichen Veröffentlichung populären sie das Backpropagation-Verfahren für mehrlagige Netze und zeigten, dass sich damit die zuvor beklagten Beschränkungen überwinden ließen. Dieser Durchbruch legte – mit jahrzehntelanger Verzögerung in der Wirkung – das Fundament für die spätere Deep-Learning-Revolution. Yann LeCun wandte das Verfahren 1989 bei den Bell Labs erfolgreich auf die Erkennung handgeschriebener Ziffern an.

Der kommerzielle Boom erwies sich jedoch als fragil. Die spezialisierten LISP-Maschinen waren teuer, und ihr Markt brach 1987 zusammen, als leistungsfähige Standard-Arbeitsplatzrechner verfügbar wurden. Expertensysteme erwiesen sich zudem als starr und wartungsintensiv. Die Folge war der zweite KI-Winter, der das Feld bis in die frühen 1990er-Jahre prägte und erneut zu einem deutlichen Rückgang der Investitionen führte.

7 Statistisches Lernen und erste öffentliche Triumphe

In den 1990er-Jahren verschob sich der Schwerpunkt von handcodierten Regeln hin zu datengetriebenen, statistischen Methoden – leiser im Ton, aber folgenreicher in der Wirkung.

Während die öffentliche Aufmerksamkeit nach dem zweiten Winter abebbte, vollzog sich im Hintergrund ein methodischer Paradigmenwechsel. Statt zu versuchen, Expertenwissen vollständig in Regeln zu gießen, setzten Forscher zunehmend auf Verfahren, die Muster unmittelbar aus Daten lernten. Ein Meilenstein war die Entwicklung der Support Vector Machines durch Corinna Cortes und Vladimir Vapnik 1995, die über Jahre zu den leistungsfähigsten Klassifikationsverfahren zählten.

Zugleich reiften die neuronalen Netze weiter. 1997 stellten Sepp Hochreiter und Jürgen Schmidhuber die Architektur des Long Short-Term Memory (LSTM) vor, die das Lernen über lange Sequenzen hinweg ermöglichte und Jahrzehnte später in der Sprachverarbeitung breite Anwendung finden sollte. Bereits 1992 hatte Gerald Tesauro mit TD-Gammon gezeigt, dass ein neuronales Netz durch selbständiges Spiel Backgammon auf Weltklasseniveau erlernen konnte.

Den symbolträchtigsten Erfolg der Dekade lieferte jedoch ein klassischer, regelbasierter Ansatz: 1997 besiegte der von IBM entwickelte Schachcomputer Deep Blue den amtierenden Weltmeister Garri Kasparow in einem Wettkampf über sechs Partien. Es war das erste Mal, dass eine Maschine einen regierenden Schachweltmeister unter Turnierbedingungen schlug – ein Ereignis von enormer öffentlicher Wirkung, das die Leistungsfähigkeit maschineller Problemlösung einer breiten Öffentlichkeit vor Augen führte.

Bezeichnenderweise beruhte Deep Blues Stärke weniger auf „Intelligenz“ im engeren Sinne als auf roher Rechenkraft und ausgefeilter Suche. Genau diese Verbindung – wachsende Rechenleistung trifft auf lernfähige, datengetriebene Verfahren – sollte im folgenden Jahrzehnt die Bühne für den eigentlichen Durchbruch bereiten.

Charakteristisch für die 1990er-Jahre ist somit ein Auseinanderfallen von öffentlicher Wahrnehmung und tatsächlichem Fortschritt. Während in der Öffentlichkeit der Eindruck vorherrschte, die KI sei gescheitert, wurden im Stillen genau jene statistischen und neuronalen Werkzeuge geschärft, die das kommende Jahrzehnt prägen sollten. Diese Phase verdeutlicht, dass technologische Reife und mediale Aufmerksamkeit keineswegs im Gleichschritt verlaufen.

8 Die Deep-Learning-Revolution

Ab Mitte der 2000er-Jahre fügten sich Daten, Rechenleistung und Algorithmen zu einer kritischen Masse zusammen. Was folgte, war der nachhaltigste Aufschwung der gesamten KI-Geschichte.

Den Auftakt markierte 2006 eine Arbeit von Geoffrey Hinton und Kollegen über tiefe Glaubensnetze (Deep Belief Networks), die zeigte, wie sich vielschichtige neuronale Netze effizient vortrainieren ließen. In diesem Zusammenhang etablierte sich der Begriff „Deep Learning“. Eine zweite Voraussetzung schuf die Hardware: Mit der Veröffentlichung der Programmierplattform CUDA durch NVIDIA 2007 wurden Grafikprozessoren für allgemeine Rechenaufgaben nutzbar und lieferten die nötige Rechenleistung für das Training großer Netze.

Die dritte Voraussetzung waren Daten. 2009 stellte die Forscherin Fei-Fei Li mit ImageNet eine Bilddatenbank mit Millionen beschrifteter Aufnahmen vor, die zum Maßstab für die Bilderkennung wurde. Der zugehörige Wettbewerb wurde zur entscheidenden Bühne: 2012 gewann das von Alex Krizhevsky, Ilya Sutskever und Geoffrey Hinton entwickelte tiefe neuronale Netz AlexNet den Wettbewerb mit großem Vorsprung und läutete damit endgültig die Ära des Deep Learning ein.

Die Jahre danach folgten Schlag auf Schlag. 2011 gewann IBMs System Watson die Quizsendung Jeopardy! gegen menschliche Champions, im selben Jahr brachte Apple den Sprachassistenten Siri auf den Markt. 2013 stellte ein Team um Tomas Mikolov bei Google das Verfahren word2vec vor, das Wörter als Vektoren darstellte. 2014 präsentierte Ian Goodfellow die Generative Adversarial Networks (GANs), die fortan realistische synthetische Bilder erzeugten; im selben Jahr übernahm Google das britische Labor DeepMind. 2015 veröffentlichte Google die quelloffene Bibliothek TensorFlow, und mit OpenAI wurde ein einflussreiches Forschungslabor gegründet.

Den vielleicht symbolträchtigsten Moment dieser Phase lieferte das Spiel Go, das wegen seiner enormen Komplexität lange als uneinnehmbare Bastion menschlicher Überlegenheit galt. Das von DeepMind entwickelte Programm AlphaGo besiegte 1999 den südkoreanischen Großmeister Lee Sedol mit 4:1 – ein Resultat, das Fachwelt und Öffentlichkeit gleichermaßen verblüffte und die Leistungsfähigkeit selbstlernender Systeme eindrucksvoll demonstrierte. 2016 setzte Google mit seinem neuronalen Übersetzungssystem (GNMT) neue Maßstäbe in der maschinellen Übersetzung, und 2017 verallgemeinerte das Nachfolgesystem AlphaZero den Ansatz auf weitere Spiele wie Schach und Shogi, das es sich allein durch Spiel gegen sich selbst beibrachte.

Den methodisch folgenreichsten Beitrag dieser Epoche lieferte 2017 eine Forschergruppe bei Google mit der Veröffentlichung „Attention Is All You Need“. Die darin vorgestellte Transformer-Architektur verzichtete auf die bisher übliche sequentielle Verarbeitung und stützte sich vollständig auf sogenannte Aufmerksamkeitsmechanismen. Sie wurde zur technischen Grundlage praktisch aller nachfolgenden großen Sprachmodelle und damit zum Wendepunkt hin zur generativen KI.

Im Rückblick unterscheidet sich diese Epoche grundlegend von den früheren Aufschwungphasen. Anders als bei den Expertensystemen der 1980er-Jahre beruhten die Fortschritte nicht auf mühsam von Hand kodiertem Wissen, sondern auf Verfahren, die sich mit wachsenden Daten- und Rechenressourcen nahezu beliebig verbessern ließen. Damit war erstmals ein sich selbst verstärkender Kreislauf entstanden: Bessere Ergebnisse zogen größere Investitionen nach sich, die wiederum bessere Ergebnisse ermöglichten.

9 Das Zeitalter der generativen Künstlichen Intelligenz

Die Transformer-Architektur entfesselte eine Welle immer größerer Sprach- und Bildmodelle, die KI binnen weniger Jahre vom Forschungsgegenstand zum Alltagswerkzeug machten.

Auf der Grundlage des Transformers entstand eine rasche Abfolge immer leistungsfähigerer Modelle. 2018 stellte Google das Sprachmodell BERT vor, das das Verständnis natürlicher Sprache deutlich verbesserte; im selben Jahr veröffentlichte OpenAI mit GPT-1 die erste Generation seiner generativen vortrainierten Transformer. 2019 folgte GPT-2, dessen Textqualität so hoch war, dass die Veröffentlichung des vollständigen Modells zunächst aus Sorge vor Missbrauch zurückgehalten wurde.

2020 markierte mit GPT-3 einen Sprung in der Größenordnung: Das Modell verfügte über 175 Milliarden Parameter und zeigte erstmals eindrucksvoll, dass reine Skalierung zu qualitativ neuen Fähigkeiten führen kann. Im selben Jahr gelang DeepMind mit AlphaFold 2 ein wissenschaftlicher Durchbruch ersten Ranges: Das System sagte die dreidimensionale Struktur von Proteinen mit bislang unerreichter Genauigkeit voraus und löste damit ein jahrzehntealtes Problem der Molekularbiologie.

2021 weiteten sich die Fähigkeiten generativer Systeme auf den Bildbereich aus. OpenAI stellte mit DALL·E ein Modell vor, das aus Textbeschreibungen Bilder erzeugte; im selben Jahr wurde das Forschungsunternehmen Anthropic gegründet, und mit GitHub Copilot erreichte die KI-gestützte Programmierung den Mainstream. 2022 folgte mit Stable Diffusion und Midjourney eine breite Verfügbarkeit leistungsfähiger Bildgeneratoren.

Den eigentlichen Wendepunkt der öffentlichen Wahrnehmung brachte jedoch der 30. November 2022: An diesem Tag veröffentlichte OpenAI den Chatbot ChatGPT. Innerhalb von nur zwei Monaten erreichte der Dienst geschätzt über hundert Millionen Nutzer und wurde damit zu einer der am schnellsten angenommenen Anwendungen der Geschichte. Wenige Monate später, im März 2023, folgte mit GPT-4 ein nochmals deutlich leistungsfähigeres Modell, während mit Metas LLaMA im selben Jahr auch quelloffene Alternativen an Bedeutung gewannen.

10 KI im Mainstream und wissenschaftliche Anerkennung

Mit der Reife der Technologie folgte die institutionelle Anerkennung – bis hin zu zwei Nobelpreisen, die im selben Jahr an KI-Pioniere vergeben wurden.

Das Jahr 2024 markierte gleich in mehrfacher Hinsicht eine Zäsur. Der Nobelpreis für Physik 2024 ging an John Hopfield und Geoffrey Hinton für ihre grundlegenden Arbeiten zu künstlichen neuronalen Netzen. Nur einen Tag später wurde der Nobelpreis für Chemie 2024 verkündet, der zur einen Hälfte an David Baker für rechnergestütztes Proteindesign und zur anderen Hälfte an Demis Hassabis und John Jumper von Google DeepMind für die Entwicklung von AlphaFold ging. Damit würdigte das Nobelkomitee in zwei Disziplinen zugleich den Beitrag der KI zur Wissenschaft.

Technologisch setzte sich die Entwicklung hin zu multimodalen Systemen fort, die Text, Bild, Audio und Video gemeinsam verarbeiten. Mit GPT-4o stellte OpenAI 2024 ein Modell vor, das Sprache nahezu in Echtzeit verarbeitete, und kündigte mit Sora ein System zur Erzeugung von Videos aus Textbeschreibungen an. Zugleich rückten autonome, handlungsfähige „Agenten“ in den Mittelpunkt der Entwicklung, die Aufgaben nicht nur beantworten, sondern eigenständig in mehreren Schritten ausführen sollen.

Parallel zur technischen Reife wuchs das Bewusstsein für Risiken. Fragen der Verlässlichkeit, der Verzerrung in Trainingsdaten, des Energieverbrauchs sowie der gesellschaftlichen Auswirkungen auf Arbeitsmärkte und öffentliche Meinung rückten in den Vordergrund. Die Diskussion um die Sicherheit fortgeschrittener Systeme – einschließlich des langfristigen Ziels einer allgemeinen KI – verlor ihren spekulativen Charakter und wurde Gegenstand ernsthafter wissenschaftlicher und politischer Befassung.

Bemerkenswert an dieser jüngsten Phase ist die Geschwindigkeit, mit der sich Forschung, Wirtschaft und Gesellschaft verzahnen. Wissenschaftliche Ergebnisse finden binnen Monaten ihren Weg in marktreife Produkte, und gesellschaftliche Debatten über Chancen und Risiken werden parallel zur technischen Entwicklung geführt, nicht erst im Nachhinein. Diese Gleichzeitigkeit unterscheidet die Gegenwart deutlich von den langen Latenzzeiten früherer Epochen, in denen zwischen Idee und Wirkung mitunter Jahrzehnte lagen.

11 Anwendungsfelder der Künstlichen Intelligenz

Die im historischen Teil beschriebenen Methoden entfalten ihre Wirkung erst in der Anwendung. Dieses Kapitel ordnet die wichtigsten Einsatzfelder ein und zeigt, wie eng technischer Fortschritt und praktischer Nutzen miteinander verflochten sind.

11.1 Maschinelles Sehen

Das maschinelle Sehen zählt zu den am frühesten und sichtbarsten von der Deep-Learning-Revolution erfassten Feldern. Der Durchbruch von AlexNet im Jahr 2012 verlagerte den Schwerpunkt von handentworfenen Bildmerkmalen hin zu Merkmalen, die das Netz selbständig aus den Daten lernt. In den Folgejahren verbesserten sich Objekterkennung, Bildsegmentierung und Gesichtserkennung rasant. Ein wichtiger architektonischer Fortschritt gelang 2015 mit den sogenannten Residualnetzen (ResNet), die das Training sehr tiefer Netze stabilisierten.

Die praktischen Anwendungen reichen von der medizinischen Bildanalyse über die industrielle Qualitätskontrolle bis zur Inhaltsmoderation auf großen Plattformen. Zugleich rückten mit der Verbreitung der Gesichtserkennung Fragen des Datenschutzes und der Verzerrung in den Vordergrund, da die Genauigkeit solcher Systeme je nach Bevölkerungsgruppe deutlich variieren kann.

11.2 Verarbeitung natürlicher Sprache

Die Verarbeitung natürlicher Sprache hat eine besonders bewegte Geschichte hinter sich. Auf die frühen, regelbasierten Übersetzungssysteme folgten in den 1990er- und frühen 2000er-Jahren statistische Verfahren, die auf großen zweisprachigen Textsammlungen beruhten. Den nächsten Sprung brachte 2016 die Einführung neuronaler Übersetzungssysteme, die ganze Sätze im Zusammenhang verarbeiteten.

Mit der Transformer-Architektur von 2017 und den darauf aufbauenden großen Sprachmodellen verschmolzen schließlich Übersetzung, Zusammenfassung, Fragebeantwortung und Texterzeugung zu einem einheitlichen Ansatz. Heute bilden diese Modelle den Kern zahlreicher Produkte, von Suchmaschinen über Schreibassistenten bis zu Programmierwerkzeugen.

11.3 Robotik und autonome Systeme

In der Robotik und bei autonomen Fahrzeugen trifft KI auf die Härte der physischen Welt. Einen viel beachteten Anstoß gaben die von der US-Forschungsagentur DARPA ausgerichteten Wettbewerbe: Bei der „Grand Challenge“ 2005 durchquerte das Fahrzeug „Stanley“ der Stanford University erstmals erfolgreich eine Wüstenstrecke autonom, und die „Urban Challenge“ 2007 verlagerte die Aufgabe in den simulierten Stadtverkehr.

Aus diesen Anfängen entwickelte sich eine ganze Industrie. Aus dem 2009 gestarteten Selbstfahr-Projekt von Google ging 2016 das eigenständige Unternehmen Waymo hervor. Parallel hielt KI in Form von Bildverarbeitung und Bewegungsplanung Einzug in die industrielle Fertigung und die Logistik, wo sie heute kollaborative Roboter und automatisierte Lagersysteme steuert.

11.4 KI in den Lebenswissenschaften

Besonders eindrucksvoll ist der Beitrag der KI zu den Lebenswissenschaften. Mit AlphaFold 2 löste DeepMind 2020 ein jahrzehntealtes Problem der Strukturbioologie, indem es die räumliche Faltung von Proteinen aus deren Aminosäuresequenz vorhersagte. Die daraus resultierende Datenbank steht der Forschung weltweit offen und hat die Arbeit in Bereichen von der Enzymforschung bis zur Wirkstoffentwicklung beschleunigt.

Über die Strukturvorhersage hinaus kommen lernende Verfahren bei der Auswertung medizinischer Bilddaten, der Analyse genetischer Informationen und der Identifikation vielversprechender Wirkstoffkandidaten zum Einsatz. Die Anerkennung dieses Beitrags durch den Nobelpreis für Chemie 2024 unterstrich die Reife des Feldes.

11.5 KI in Wirtschaft, Finanzwesen und Verwaltung

In Wirtschaft und Verwaltung wirkt KI häufig unsichtbar im Hintergrund. Empfehlungssysteme prägen den elektronischen Handel und die Medienwirtschaft, während im Finanzwesen lernende Modelle der Betrugserkennung, der Risikobewertung und der Prognose dienen. In der öffentlichen Verwaltung reichen die Anwendungen von der automatisierten Bearbeitung von Anträgen bis zur Analyse großer Datenbestände.

Mit dem Aufkommen generativer Modelle hat sich das Anwendungsspektrum nochmals erweitert. Aufgaben wie das Verfassen von Entwürfen, das Zusammenfassen von Dokumenten oder die Beantwortung von Kundenanfragen lassen sich heute teilautomatisieren. Gerade hier ist jedoch die bereits erwähnte Anfälligkeit für inhaltliche Fehler zu beachten: Automatisiert erzeugte Texte bedürfen einer sorgfältigen fachlichen Prüfung, bevor sie als verlässliche Grundlage dienen.

11.6 Kreativwirtschaft und Medien

Mit den generativen Modellen hat die KI ein Feld erreicht, das lange als ureigene menschliche Domäne galt: das kreative Schaffen. Systeme erzeugen heute Texte, Illustrationen, Musik und sogar Videosequenzen aus knappen Beschreibungen. Für die Kreativwirtschaft eröffnet dies neue Werkzeuge, wirft zugleich aber drängende Fragen zu Urheberrecht, Vergütung und der Abgrenzung menschlicher von maschineller Urheberschaft auf.

Eine besondere Herausforderung stellen täuschend echte synthetische Inhalte dar. Sogenannte Deepfakes können Personen Aussagen oder Handlungen unterschieben, die nie stattgefunden haben. Als Gegenmaßnahme gewinnen Verfahren zur Kennzeichnung und Herkunftsnachverfolgung von Inhalten an Bedeutung, etwa digitale Wasserzeichen und überprüfbare Echtheitsnachweise.

11.7 Bildung und Wissenschaft

In Bildung und Wissenschaft wirken lernende Systeme als Werkzeuge der Wissensvermittlung und der Forschung. Sie ermöglichen individuell angepasste Lernangebote, unterstützen beim Recherchieren und Zusammenfassen und erschließen große wissenschaftliche Textbestände. In der Forschung selbst beschleunigen sie die Auswertung von Messdaten und die Generierung von Hypothesen.

Diesen Chancen stehen Risiken gegenüber. Eine unkritische Übernahme maschinell erzeugter Antworten kann zu einer Erosion eigenständigen Denkens und zur Verbreitung von Fehlinformationen führen. Gerade im Bildungskontext ist daher die Fähigkeit zentral, Quellen zu bewerten und Aussagen zu überprüfen, statt sie ungeprüft zu übernehmen.

12 Schlüsselfiguren der KI-Geschichte

Hinter den Meilensteinen stehen Persönlichkeiten, deren Werdegang die Entwicklung des Feldes über Jahrzehnte geprägt hat. Die folgende Auswahl porträtiert einige besonders einflussreiche Köpfe.

Alan Turing (1912–1954). Der britische Mathematiker gilt als einer der Begründer der theoretischen Informatik. Seine bereits 1936 entwickelte Idee einer universellen Rechenmaschine steckte die Grenzen des maschinell Berechenbaren ab; der nach ihm benannte Test zur maschinellen Intelligenz prägt die Debatte bis heute.

John McCarthy (1927–2011). Der amerikanische Informatiker entwickelte 1958 die Programmiersprache LISP und war eine treibende Kraft hinter dem Gründungsworkshop des Feldes. Auf ihn geht maßgeblich die Etablierung der Künstlichen Intelligenz als eigenständige Disziplin zurück.

Marvin Minsky (1927–2016). Mitbegründer des KI-Labors am MIT, lieferte grundlegende Beiträge zur symbolischen KI. Seine gemeinsam mit Seymour Papert 1969 verfasste Kritik einlagiger neuronaler Netze beeinflusste die Forschung über viele Jahre.

Frank Rosenblatt (1928–1971). Der Psychologe stellte 1958 mit dem Perceptron eines der ersten lernfähigen neuronalen Modelle vor und legte damit einen Grundstein für die spätere Entwicklung künstlicher neuronaler Netze.

Geoffrey Hinton (geb. 1947). Der britisch-kanadische Forscher, oft als einer der „Paten“ des Deep Learning bezeichnet, war an der Popularisierung der Backpropagation 1986 ebenso beteiligt wie am Erfolg von AlexNet 2012. Für seine Arbeiten erhielt er 2018 den Turing Award und 2024 den Nobelpreis für Physik.

Yann LeCun (geb. 1960). Der französische Forscher wandte das Backpropagation-Verfahren 1989 erfolgreich auf die Erkennung handgeschriebener Ziffern an und prägte die Entwicklung faltender neuronaler Netze. Auch er wurde 2018 mit dem Turing Award ausgezeichnet.

Yoshua Bengio (geb. 1964). Der kanadische Forscher leistete zentrale Beiträge zum Deep Learning und zur Verarbeitung natürlicher Sprache. Gemeinsam mit Hinton und LeCun erhielt er 2018 den Turing Award.

Jürgen Schmidhuber (geb. 1963). Der deutsche Informatiker entwickelte gemeinsam mit Sepp Hochreiter 1997 die LSTM-Architektur, die das Lernen über lange Sequenzen ermöglichte und die Sprachverarbeitung nachhaltig prägte.

Fei-Fei Li (geb. 1976). Die Informatikerin schuf 2009 mit ImageNet die Datengrundlage, die den Wettbewerb um die Bilderkennung und damit die Deep-Learning-Revolution maßgeblich befeuerte.

Demis Hassabis (geb. 1976). Der britische Forscher gründete 2010 das Labor DeepMind, dessen Programme das Spiel Go meisterten und mit AlphaFold die Strukturbioologie revolutionierten. 2024 wurde ihm der Nobelpreis für Chemie zuerkannt.

Allen Newell (1927–1992) und Herbert A. Simon (1916–2001). Das Forscherduo legte mit dem „Logic Theorist“ und dem „General Problem Solver“ Grundsteine der symbolischen KI. Beide erhielten 1975 den Turing Award; Simon wurde zudem für seine Arbeiten zur Entscheidungsfindung mit dem Nobelgedächtnispreis für Wirtschaftswissenschaften ausgezeichnet.

Sepp Hochreiter (geb. 1967). Der österreichische Informatiker entwickelte als Doktorand die Grundidee des Long Short-Term Memory und trug damit entscheidend zur Lösung eines zentralen Problems beim Training rekurrenter Netze bei.

Ilya Sutskever (geb. 1986). Der Forscher war an AlexNet beteiligt und zählt zu den prägenden Köpfen hinter der Entwicklung großer generativer Sprachmodelle. Sein Werdegang steht beispielhaft für den Übergang von der akademischen Forschung zur industriellen KI-Entwicklung.

13 Markt- und Investitionsanalyse

Die technologische Entwicklung spiegelt sich in einer ausgeprägten Dynamik von Investitionen, Unternehmensgründungen und Marktvolumina wider.

Die ökonomische Bedeutung der KI hat sich im Verlauf der hier betrachteten Epochen grundlegend gewandelt. Während die frühen Jahrzehnte fast ausschließlich von staatlicher und militärischer Forschungsförderung getragen wurden, verlagerte sich das Gewicht ab den 1980er-Jahren zunehmend in die Privatwirtschaft. Mit der Deep-Learning-Revolution schließlich wurde KI zu einem der zentralen Investitionsfelder der globalen Technologiebranche.

13.1 Entwicklung des geschätzten Marktvolumens

Die nachstehende Übersicht fasst gängige Größenordnungen für das weltweite Marktvolumen KI-bezogener Produkte und Dienstleistungen zusammen. Die Werte sind als grobe Orientierung zu verstehen, da die Abgrenzung des Marktes je nach Quelle erheblich variiert.

Jahr	Geschätztes Marktvolumen (global)	Wesentlicher Treiber
2012	wenige Milliarden US-Dollar	Frühe Bilderkennung, erste Cloud-Dienste
2015	zweistelliger Milliardenbereich	Verbreitung von Deep-Learning-Frameworks
2018	mittlerer zweistelliger Milliardenbereich	Sprachmodelle, Unternehmens-Pilotprojekte
2020	hoher zweistelliger Milliardenbereich	Skalierung großer Modelle
2022	dreistelliger Milliardenbereich	Generative KI, ChatGPT-Effekt
2024	mehrere hundert Milliarden US-Dollar	Breite Unternehmensintegration
2026 (Prognose)	anhaltend starkes Wachstum	Agentische Systeme, Multimodalität

Tabelle 2: Grobe Größenordnungen des geschätzten globalen KI-Marktvolumens. Quellen variieren stark; Werte dienen nur der Veranschaulichung.

13.2 Ausgewählte Meilensteine aus Industrie und Forschung

Die folgende Aufstellung ordnet zentrale organisatorische und technische Ereignisse den jeweiligen Akteuren zu und verdeutlicht die zunehmende Verlagerung der Innovationskraft in privatwirtschaftliche Labore.

Jahr	Akteur	Ereignis
2010	DeepMind	Gründung des Labors in London
2011	IBM	Watson gewinnt die Quizsendung Jeopardy!
2012	Universität Toronto	AlexNet gewinnt den ImageNet-Wettbewerb
2014	Google	Übernahme von DeepMind
2015	Google / OpenAI	TensorFlow veröffentlicht; OpenAI gegründet
2017	Google	Transformer-Architektur veröffentlicht
2020	OpenAI / DeepMind	GPT-3 vorgestellt; AlphaFold 2 löst Proteinfaltung
2022	OpenAI	Veröffentlichung von ChatGPT

Jahr	Akteur	Ereignis
2023	OpenAI / Meta	GPT-4 vorgestellt; LLaMA als offenes Modell
2024	Nobelkomitee	Nobelpreise für Physik und Chemie an KI-Pioniere

Tabelle 3: Ausgewählte Meilensteine aus Industrie und Forschung.

13.3 Regionale und strukturelle Betrachtung

Die Wertschöpfung im KI-Sektor verteilt sich höchst ungleich. Ein Großteil der grundlegenden Modelle, der Rechenkapazität und des Risikokapitals konzentriert sich auf wenige Regionen, während die Anwendung weltweit erfolgt. Diese Asymmetrie zwischen Entwicklung und Nutzung prägt die geopolitische Debatte um technologische Souveränität.

Region	Strukturelle Stärke	Einordnung
Nordamerika	Führende Modelle, Risikokapital, Cloud-Infrastruktur	Dominanz bei großen generativen Modellen
Ostasien	Halbleiterfertigung, Hardware, Anwendungsbreite	Starke industrielle Integration
Europa	Forschung, Regulierung, industrielle Anwendung	Vorreiter bei Rahmensetzung, EU AI Act
Übrige Welt	Wachsende Adaption, Talentbasis	Zunehmende Bedeutung als Anwender und Talentquelle

Tabelle 4: Grobe regionale Einordnung struktureller Stärken (qualitativ).

Drei strukturelle Treiber bestimmen die künftige Dynamik. Erstens die Rechenleistung: Das Training großer Modelle erfordert spezialisierte Prozessoren in großem Maßstab, was die Lieferketten für Halbleiter zu einem strategischen Faktor macht. Zweitens die Daten: Qualität, Umfang und rechtliche Verfügbarkeit von Trainingsdaten entscheiden über die Leistungsfähigkeit der Systeme. Drittens das Fachkräfteangebot, um das ein intensiver internationaler Wettbewerb herrscht.

Aus Investitionssicht ist die jüngste Phase von einer Verschiebung gekennzeichnet: Während frühe Mittel überwiegend in die Grundlagenforschung flossen, richtet sich das Kapital zunehmend auf Infrastruktur, anwendungsnahe Produkte und die Integration in bestehende Geschäftsmodelle. Damit gewinnt die Frage an Gewicht, ob den hohen Bewertungen ein entsprechender, nachhaltiger Ertrag gegenübersteht.

14 Regulierung, Risiken und Ausblick

Mit der wirtschaftlichen Bedeutung wuchs der Bedarf an verbindlichen Regeln. Die kommende Dekade wird maßgeblich davon geprägt, wie Innovation und Verantwortung in Einklang gebracht werden.

Die rasante Verbreitung generativer Systeme hat den regulatorischen Druck erhöht. Als weltweit erster umfassender Rechtsrahmen trat 2024 die KI-Verordnung der Europäischen Union (EU AI Act) in Kraft, die KI-Anwendungen nach ihrem Risiko in Kategorien einteilt und für Hochrisiko-Anwendungen strenge Anforderungen vorsieht. Die Bestimmungen werden über mehrere Jahre hinweg schrittweise wirksam und entfalten bereits eine internationale Vorbildwirkung.

Inhaltlich kreisen die regulatorischen Debatten um wiederkehrende Themen: die Transparenz und Nachvollziehbarkeit von Entscheidungen, den Schutz personenbezogener Daten, die Kennzeichnung KI-generierter Inhalte sowie die Haftung bei fehlerhaften Ergebnissen. Ein besonderes Augenmerk gilt der Verlässlichkeit großer Sprachmodelle, die plausibel klingende, aber sachlich falsche Aussagen erzeugen können – ein Phänomen, das in der Fachdiskussion als „Halluzination“ bezeichnet wird und gerade bei der automatisierten Erstellung von Dokumenten sorgfältige Prüfprozesse erfordert.

Für die kommenden Jahre zeichnen sich mehrere Entwicklungslinien ab. Erstens dürfte die Integration von KI in bestehende Software und Geschäftsprozesse weiter voranschreiten und damit von einer eigenständigen Anwendung zu einer allgegenwärtigen Infrastruktur werden. Zweitens verschiebt sich der Fokus von reinen Sprach- und Bildmodellen hin zu handlungsfähigen Agenten und multimodalen Systemen. Drittens gewinnt die Frage der Effizienz an Gewicht, da der Energie- und Ressourcenbedarf großer Modelle zunehmend in den Blick gerät.

Die historische Betrachtung mahnt dabei zur Nüchternheit. Die KI-Geschichte ist reich an Phasen, in denen kurzfristige Erwartungen die tatsächlichen Fähigkeiten weit überstiegen und in Enttäuschung mündeten. Zugleich zeigt sie, dass tragfähige Grundideen auch lange Durststrecken überdauern und schließlich Wirkung entfalten, sobald die nötige Infrastruktur verfügbar ist. Ob die gegenwärtige Welle in einen weiteren Winter mündet oder in eine dauerhafte Integration, wird sich daran entscheiden, ob den Erwartungen ein entsprechender, breit verteilter wirtschaftlicher Nutzen gegenübersteht.

15 Vertiefung: Die drei Treiber des Durchbruchs

Warum gelang der Durchbruch des Deep Learning ausgerechnet ab Mitte der 2000er-Jahre – und nicht früher? Die Antwort liegt im Zusammenspiel dreier Faktoren, die erst gemeinsam eine kritische Masse bildeten.

15.1 Daten als Rohstoff

Lernende Systeme sind nur so gut wie die Daten, aus denen sie lernen. Über Jahrzehnte war die Verfügbarkeit großer, sauber beschrifteter Datensätze der limitierende Faktor. Die Vorstellung der Bilddatenbank ImageNet 2009 markierte hier einen Wendepunkt: Erstmals stand eine Datensammlung in einer Größenordnung zur Verfügung, die das Training sehr großer Netze sinnvoll machte. Mit der Verbreitung des Internets wuchs zudem die Menge frei verfügbarer Texte, Bilder und Videos ins Unermessliche.

Mit der Datenmenge wuchsen jedoch auch die Probleme. Verzerrungen in den Trainingsdaten übertragen sich auf die Modelle, urheber- und datenschutzrechtliche Fragen gewinnen an Schärfe, und die Qualität der Daten entscheidet maßgeblich über die Verlässlichkeit der Ergebnisse. Die Beschaffung, Bereinigung und rechtssichere Nutzung von Daten ist damit zu einer eigenen, wettbewerbsentscheidenden Disziplin geworden.

15.2 Rechenleistung

Der zweite Treiber ist die Rechenleistung. Viele der heute zentralen Verfahren waren im Prinzip seit den 1980er-Jahren bekannt, ließen sich aber mangels Rechenkraft nicht im erforderlichen Maßstab anwenden. Den entscheidenden Hebel lieferte die Erkenntnis, dass sich Grafikprozessoren hervorragend für das Training neuronaler Netze eignen. Die Veröffentlichung der Plattform CUDA durch NVIDIA 2007 machte diese Rechenkraft breit nutzbar.

Seither hat sich die für Spitzenmodelle eingesetzte Rechenleistung in immer kürzeren Abständen vervielfacht. Dieser Trend hat spezialisierte Beschleuniger hervorgebracht und den Bau großer Rechenzentren zu einer strategischen Investition gemacht. Zugleich rückt der damit verbundene Energie- und Ressourcenbedarf zunehmend in den Mittelpunkt der Nachhaltigkeitsdebatte.

15.3 Algorithmen und das Skalierungsparadigma

Der dritte Treiber sind die Algorithmen selbst. Auf das 1986 populär gewordene Backpropagation-Verfahren folgten mit den tiefen Glaubensnetzen von 2006 und dem Erfolg von AlexNet 2012 entscheidende Fortschritte. Den vorläufigen Höhepunkt bildete die Transformer-Architektur von 2017, die sich als außerordentlich gut skalierbar erwies.

Daraus erwuchs das prägende Paradigma der jüngsten Phase: die Beobachtung, dass sich die Leistungsfähigkeit von Modellen mit wachsender Größe, Datenmenge und Rechenleistung in vorhersagbarer Weise verbessert. Die Vorstellung von GPT-3 im Jahr 2020 lieferte dafür einen eindrucksvollen Beleg. Ob sich dieses Skalierungsversprechen unbegrenzt fortsetzen lässt oder an Grenzen stößt, zählt zu den wichtigsten offenen Fragen des Feldes.

16 Fazit

Die Geschichte der Künstlichen Intelligenz lässt sich als Abfolge von sechs Epochen lesen, die jeweils durch ein charakteristisches Zusammenspiel von Theorie, Technik und ökonomischen Rahmenbedingungen geprägt waren. Von den kybernetischen und logischen Grundlagen der 1940er- und 1950er-Jahre über die Gründungsphase, die beiden KI-Winter und die Renaissance des statistischen Lernens bis hin zur Deep-Learning-Revolution und dem aktuellen Zeitalter generativer Modelle zieht sich ein roter Faden: Der begrenzende Faktor war selten die fehlende Idee, sondern die fehlende Infrastruktur, um sie zur Wirkung zu bringen.

Für Entscheiderinnen und Entscheider ergeben sich daraus zwei Lehren. Zum einen lohnt ein gesunder Realismus gegenüber kurzfristigen Heilsversprechen, da die Geschichte zeigt, wie schnell überzogene Erwartungen in Ernüchterung umschlagen. Zum anderen wäre es ein Fehler, die Technologie zu unterschätzen: Gerade weil die heutigen Systeme auf jahrzehntelang gereiften Grundlagen beruhen und nun erstmals über die nötige Infrastruktur verfügen, ist ihre Wirkung auf Wirtschaft und Gesellschaft von struktureller, nicht bloß vorübergehender Natur.

Ende des Berichts. — Aurelius Research Group, Technology Intelligence Division. Die in diesem Dokument enthaltenen Einschätzungen stellen keine Anlage-, Rechts- oder sonstige Beratung dar.

Anhang A Glossar zentraler Begriffe

Künstliche Intelligenz (KI). Sammelbegriff für Verfahren, mit denen Maschinen Aufgaben übernehmen, die menschliche Intelligenz erfordern.

Maschinelles Lernen. Teilgebiet der KI, in dem Systeme Muster aus Daten lernen, statt explizit programmiert zu werden. Der Begriff geht auf Arthur Samuel zurück.

Neuronales Netz. Rechenmodell aus vielen einfachen, miteinander verbundenen Einheiten, inspiriert von der Funktionsweise biologischer Nervenzellen.

Deep Learning. Maschinelles Lernen mit tiefen, vielschichtigen neuronalen Netzen; ab Mitte der 2000er-Jahre dominierend.

Backpropagation. Verfahren zur Anpassung der Gewichte mehrlagiger neuronaler Netze durch Fehlerrückführung; 1986 breit popularisiert.

Perceptron. Frühes, von Frank Rosenblatt 1958 vorgestelltes neuronales Modell zur Mustererkennung.

Expertensystem. Regelbasiertes Programm, das Fachwissen in Form von Wenn-dann-Regeln abbildet; prägend für die 1980er-Jahre.

Symbolische KI. Ansatz, der Intelligenz als regelgeleitete Manipulation von Symbolen auffasst; dominierte die Gründerjahre.

Transformer. 2017 vorgestellte neuronale Architektur, die vollständig auf Aufmerksamkeitsmechanismen beruht und die Grundlage moderner Sprachmodelle bildet.

Großes Sprachmodell (LLM). Auf sehr großen Textmengen trainiertes Modell zur Verarbeitung und Erzeugung natürlicher Sprache.

Generative KI. Systeme, die neue Inhalte wie Texte, Bilder, Audio oder Videos erzeugen.

Halluzination. Bezeichnung für plausibel klingende, aber sachlich falsche Ausgaben generativer Modelle.

KI-Winter. Phase stark zurückgehender Förderung und Aufmerksamkeit nach überzogenen Erwartungen; historisch v. a. in den 1970er- und späten 1980er-Jahren.

Turing-Test. Von Alan Turing vorgeschlagenes Verfahren, um maschinelle Intelligenz an der Ununterscheidbarkeit von menschlichem Verhalten zu messen.

GAN. Generative Adversarial Network; 2014 vorgestelltes Verfahren, bei dem zwei Netze gegeneinander trainiert werden, um realistische Inhalte zu erzeugen.

Multimodalität. Fähigkeit eines Systems, mehrere Datenarten – etwa Text, Bild und Audio – gemeinsam zu verarbeiten.

Agentische KI. Systeme, die Aufgaben nicht nur beantworten, sondern eigenständig in mehreren Schritten planen und ausführen.

Parameter. Die anpassbaren Gewichte eines neuronalen Netzes; ihre Anzahl gilt als grobes Maß für die Modellgröße.

Konnektionismus. Forschungsrichtung, die Intelligenz aus dem Zusammenwirken vieler einfacher, vernetzter Einheiten erklärt; Gegenpol zur symbolischen KI.

Überwachtes Lernen. Lernverfahren, bei dem das System aus Beispielen mit bekannter, vorgegebener Lösung lernt.

Unüberwachtes Lernen. Lernverfahren, das Strukturen und Muster in Daten ohne vorgegebene Zielwerte aufdeckt.

Bestärkendes Lernen. Lernverfahren, bei dem ein System durch Belohnung und Bestrafung erwünschtes Verhalten erlernt; Grundlage vieler spielender Systeme.

Faltungsnetz (CNN). Auf die Verarbeitung von Bildern spezialisierte neuronale Architektur, die lokale Muster über das gesamte Bild erkennt.

Rekurrentes Netz (RNN). Neuronale Architektur zur Verarbeitung von Sequenzen, bei der Ausgaben in den nächsten Schritt zurückfließen.

Aufmerksamkeitsmechanismus. Verfahren, das es einem Modell erlaubt, gezielt relevante Teile der Eingabe zu gewichten; Kernbestandteil der Transformer.

Überanpassung. Unerwünschter Zustand, in dem ein Modell die Trainingsdaten auswendig lernt, statt verallgemeinerbare Muster zu erfassen.

Feinabstimmung. Nachträgliche Anpassung eines vortrainierten Modells an eine spezifische Aufgabe mit vergleichsweise wenigen Daten.

Token. Kleinste Verarbeitungseinheit eines Sprachmodells, etwa ein Wort oder Wortbestandteil.

Prompt. Die Eingabeaufforderung, mit der ein generatives Modell zu einer Ausgabe veranlasst wird.

Starke und schwache KI. Schwache KI ist auf eng umrissene Aufgaben spezialisiert; starke KI bezeichnet eine bislang hypothetische, allgemeine Intelligenz.

Anhang B Hinweise zur weiterführenden Literatur

Die folgende, bewusst knapp gehaltene Auswahl nennt Werkkategorien und Themenfelder, die sich zur Vertiefung der im Bericht behandelten Epochen eignen. Sie erhebt keinen Anspruch auf Vollständigkeit.

- Grundlagenwerke zur Geschichte der Kybernetik und der frühen Informatik, die den Übergang von der Logik zur Maschinenintelligenz nachzeichnen.
- Übersichtsdarstellungen zur Entwicklung künstlicher neuronaler Netze, von den frühen Modellen bis zur Backpropagation und zum Deep Learning.
- Fachliteratur zu Expertensystemen und zur Wissensrepräsentation, die den Aufstieg und Niedergang der symbolischen KI dokumentiert.
- Aktuelle Standardlehrbücher zum maschinellen Lernen und zu großen Sprachmodellen, die den heutigen Stand der Technik systematisch aufbereiten.
- Berichte und Stellungnahmen zu Regulierung, Sicherheit und gesellschaftlichen Auswirkungen, einschließlich der europäischen KI-Verordnung.

Bei der Nutzung KI-gestützt erstellter Übersichten – wie auch des vorliegenden Berichts – empfiehlt sich grundsätzlich eine eigenständige Überprüfung einzelner Angaben anhand von Primärquellen, insbesondere bei Jahreszahlen, Namen und quantitativen Werten.

Anhang C Zur Methodik der Marktschätzungen

Die in Kapitel 13 genannten Marktgrößen sind mit erheblicher Unsicherheit behaftet. Das liegt zunächst an der Abgrenzung des Marktes: Je nachdem, ob ausschließlich spezialisierte KI-Software gezählt wird oder auch die zugehörige Hardware, Beratungsleistungen und integrierte Funktionen in bestehenden Produkten, ergeben sich stark voneinander abweichende Werte. Ein einheitlicher, allgemein akzeptierter Marktbegriff existiert nicht.

Hinzu kommt, dass viele Anbieter ihre KI-bezogenen Umsätze nicht gesondert ausweisen. Schätzungen beruhen daher häufig auf Hochrechnungen, Befragungen und Annahmen über Wachstumsraten, die ihrerseits fortgeschrieben werden. Kleine Unterschiede in den Ausgangsannahmen führen über mehrere Jahre zu großen Abweichungen in den Endwerten. Prognosen, die weit in die Zukunft reichen, sind entsprechend vorsichtig zu interpretieren.

Für die Zwecke dieses Berichts wurden die Angaben bewusst auf Größenordnungen reduziert und nicht als exakte Zahlen dargestellt. Sie sollen die Dynamik und die relative Entwicklung veranschaulichen, nicht eine Scheingenauigkeit suggerieren. Wer belastbare Zahlen für konkrete Entscheidungen benötigt, sollte auf die jeweils aktuellen Primärquellen spezialisierter Marktforschungsinstitute zurückgreifen und deren Methodik kritisch prüfen.

Anhang D Hinweise zur Prüfung KI-gestützt erstellter Inhalte

Da auch der vorliegende Bericht unter Einsatz generativer KI entstanden ist, erscheint ein kurzer Hinweis zu typischen Fehlerquellen solcher Verfahren angebracht. Generative Modelle erzeugen Texte, die sprachlich überzeugend wirken, ohne dass damit eine Gewähr für die sachliche Richtigkeit verbunden wäre. Die flüssige, selbstsichere Darstellung verleitet dazu, Angaben ungeprüft zu übernehmen.

Besonders fehleranfällig sind konkrete, überprüfbare Einzelangaben. Dazu zählen Jahreszahlen und Datumsangaben, Eigennamen und Zuordnungen von Personen zu Ereignissen sowie quantitative Werte wie Beträge, Anteile oder Mengen. Nicht selten werden plausible, aber falsche Werte erzeugt oder Ereignisse zeitlich verschoben. Auch das Vermischen ähnlicher Sachverhalte oder Personen kommt vor.

Als Faustregel empfiehlt sich daher, jede für eine Entscheidung wesentliche Tatsachenbehauptung gegen mindestens eine unabhängige, verlässliche Primärquelle abzugleichen. Gerade bei historischen Darstellungen lohnt es sich, einzelne Jahreszahlen gezielt zu verifizieren, da sich Fehler hier besonders leicht einschleichen und zugleich besonders folgenreich sein können. Eine kritische, quellenbasierte Lektüre bleibt durch keine noch so überzeugende automatische Darstellung ersetzbar.

Anhang E Häufige Missverständnisse über Künstliche Intelligenz

Zum Abschluss seien einige verbreitete Fehlvorstellungen aufgegriffen, die eine nüchterne Einordnung erschweren. Sie zu kennen, hilft dabei, sowohl überzogene Erwartungen als auch unbegründete Ängste einzuordnen.

„Künstliche Intelligenz ist eine neue Erfindung.“ Wie dieser Bericht zeigt, reichen die Grundlagen weit in die Mitte des 20. Jahrhunderts zurück. Neu sind nicht die Grundideen, sondern die Datenmengen und die Rechenleistung, die deren Umsetzung im großen Maßstab erst ermöglichen.

„Die Systeme verstehen, was sie tun.“ Große Sprachmodelle erzeugen Ausgaben auf der Grundlage statistischer Muster in ihren Trainingsdaten. Ein Verständnis im menschlichen Sinne ist damit nicht verbunden; überzeugende Formulierungen sind kein Beleg für inhaltliche Richtigkeit.

„Mehr Daten und Rechenleistung lösen jedes Problem.“ Die Skalierung hat beeindruckende Fortschritte gebracht, stößt aber an Grenzen. Datenqualität, Energiebedarf und grundsätzliche methodische Beschränkungen lassen sich nicht allein durch Größe überwinden.

„Eine allgemeine, menschenähnliche KI steht unmittelbar bevor.“ Trotz der jüngsten Fortschritte bleibt die starke KI eine offene Forschungsfrage. Zwischen den heutigen, auf bestimmte Aufgaben spezialisierten Systemen und einer allgemeinen Intelligenz besteht weiterhin eine erhebliche, in ihrem Ausmaß umstrittene Lücke.

„KI ist objektiv und neutral.“ Da lernende Systeme ihre Muster aus Daten beziehen, übernehmen sie auch die in diesen Daten enthaltenen Verzerrungen. Objektivität ist keine Eigenschaft der Technik an sich, sondern Ergebnis sorgfältiger Gestaltung, Prüfung und Kontrolle.

Anhang F Lernparadigmen im Überblick

Zum besseren Verständnis der im Bericht verwendeten Begriffe seien die drei grundlegenden Lernparadigmen des maschinellen Lernens kurz gegenübergestellt. Sie unterscheiden sich vor allem darin, welche Art von Rückmeldung dem System beim Lernen zur Verfügung steht.

Überwachtes Lernen

Beim überwachten Lernen erhält das System eine große Zahl von Beispielen, zu denen jeweils die korrekte Antwort bekannt ist – etwa Bilder mit der Angabe, was darauf zu sehen ist. Aus diesen Paaren lernt das Modell eine Zuordnung, die es anschließend auf neue, unbekannte Fälle überträgt. Dieses Paradigma ist die Grundlage vieler praktischer Anwendungen, von der Bilderkennung bis zur Spracherkennung, setzt jedoch aufwendig beschriftete Daten voraus.

Unüberwachtes Lernen

Beim unüberwachten Lernen fehlen vorgegebene Antworten. Das System soll stattdessen selbständig Strukturen in den Daten aufdecken, etwa Gruppen ähnlicher Objekte bilden oder die Daten auf wenige aussagekräftige Dimensionen verdichten. Dieses Paradigma ist besonders wertvoll, wo beschriftete Daten fehlen, liefert aber schwerer zu bewertende Ergebnisse. Auch das Vortrainieren großer Sprachmodelle auf riesigen Textmengen beruht im Kern auf einer Form des selbstüberwachten Lernens.

Bestärkendes Lernen

Beim bestärkenden Lernen handelt ein System in einer Umgebung und erhält für sein Verhalten Belohnungen oder Bestrafungen. Über viele Durchläufe hinweg lernt es, jene Handlungsfolgen zu bevorzugen, die langfristig den größten Ertrag versprechen. Dieses Paradigma hat besonders bei spielenden Systemen eindrucksvolle Erfolge erzielt und kommt zunehmend auch bei der Feinabstimmung großer Modelle an menschliche Präferenzen zum Einsatz.

In der Praxis werden diese Paradigmen häufig kombiniert. Moderne Systeme durchlaufen typischerweise mehrere Phasen – etwa ein breites Vortraining gefolgt von einer aufgabenspezifischen Feinabstimmung –, in denen unterschiedliche Lernformen zum Tragen kommen. Die Wahl des passenden Paradigmas hängt stets von der Aufgabe, der Datenlage und den verfügbaren Ressourcen ab.